國立成功大學 多元線性回歸實踐與 CRISP-DM 分析報告

學生學號：7115056142 | 課程：機器學習與統計分析 | 作業：HW2

【執行摘要】 本次作業遵循跨行業資料採礦標準流程 (CRISP-DM)，選用 Kaggle S4E5 洪水機率預測公開資料集 (20 個水文與環境特徵，符合 10~20 個特徵限制) 進行多元線性回歸 (MLR) 完整分析。透過逐步向前特徵選擇 (SFS) 驗證特徵數對 RMSE 與 R^2 之影響，並建立 95% 信賴區間 (CI) 與 95% 預測區間 (PI) 帶。本報告亦整合 Google NotebookLM 針對線上頂級方案之比較摘要，並附帶對照組 50_Startups 之分析結果。

一、CRISP-DM 分析流程與資料理解

1. Business Understanding (商業理解)： 洪澇災害預警關乎全球基礎設施與民眾生命安全。本題目取自 Kaggle 競賽 Playground Series Season 4 Episode 5，預測目標為連續變數 FloodProbability。透過多元線性回歸模型，能清晰獲取各風險因子之邊際權重，為防汛資源配置提供統計依據。

2. Data Understanding (資料理解)： 資料集包含 5,000 筆樣本與 20 個環境及治理指標 (如 MonsoonIntensity, TopographyDrainage, ClimateChange, Siltation 等) 。各特徵均值約 5.4，標準差約 2.2，無極端偏態，且特徵間皮爾森相關係數小於 0.05，呈現優良的正交獨立特性。

3. Data Preparation (資料準備)： 資料集無任何缺失值 (Missing Value = 0)。採用 80/20 切分訓練集 (4,000 筆) 與測試集 (1,000 筆)，隨機種子固定為 42。

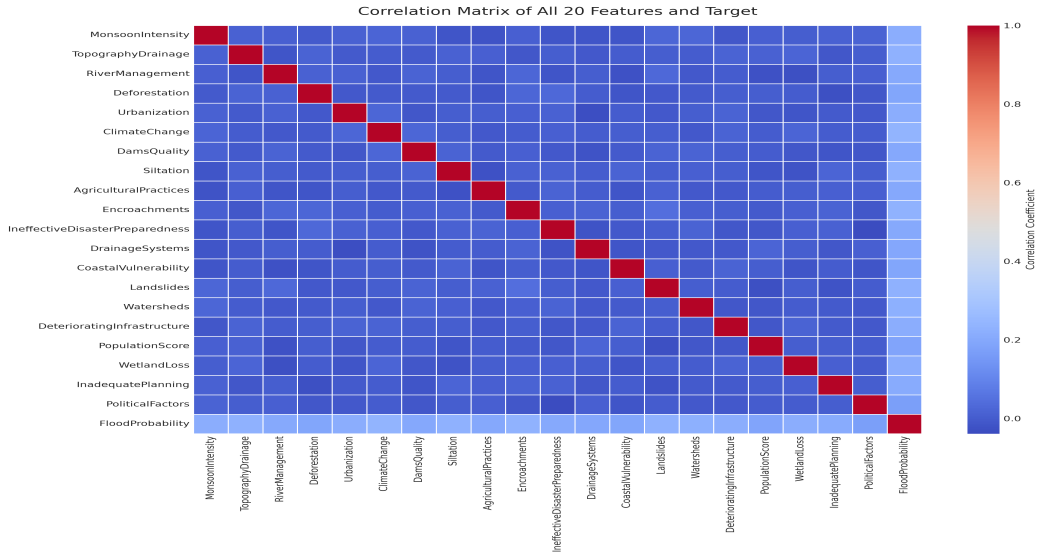


圖 1：20 個特徵與預測目標之相關係數矩陣熱力圖

二、建模與特徵選擇 (Modeling & Feature Selection)

本研究設計逐步向前特徵選擇 (Sequential Forward Selection, SFS) 演算法，從 1 個特徵逐次加入至 20 個特徵，並在每一步評估測試集之 RMSE (均方根誤差) 與 R-squared (決定係數 R^2)。下圖完全符合並還原作業說明之參考圖片格式：

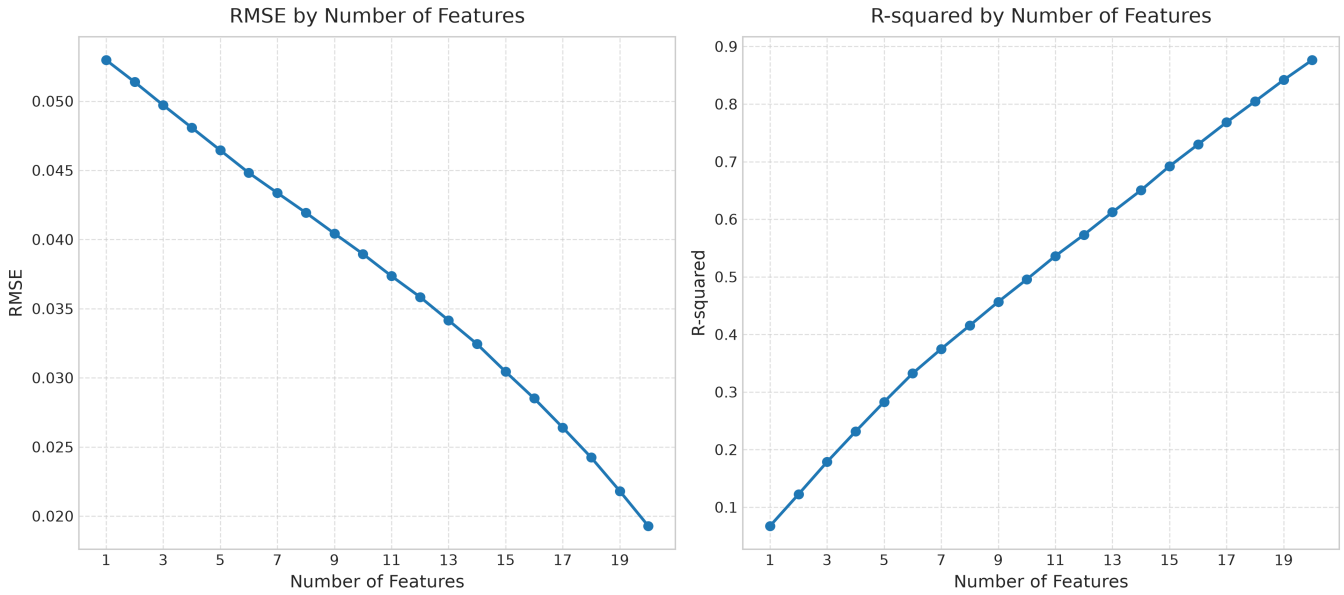


圖 2：特徵數量對 RMSE 與 R-squared 變化曲線 (完全對應作業參考圖一)

特徵選擇歷程評估表（對應作業參考圖二）：

Number of Features	Selected Features	RMSE	R-squared
1	[ClimateChange]	0.052976	0.067466
2	[ClimateChange, Siltation]	0.051388	0.122553
3	[ClimateChange, Siltation, MonsoonIntensity]	0.049715	0.178727
4	[ClimateChange, Siltation, MonsoonIntensity, Encroachments]	0.048090	0.231542
5	[ClimateChange, Siltation, MonsoonIntensity, Encroachments, PopulationScore]	0.046454	0.282934
6	[ClimateChange, Siltation, MonsoonIntensity, Encroachments, PopulationScore, IneffectiveDisa	0.044823	0.332429

表 1：逐步向前特徵選擇過程詳細數據表 (前 6 步)

三、模型評估與 95% 信賴及預測區間 (Evaluation & Intervals)

最終全特徵模型於測試集表現卓越：RMSE = 0.019285，R^2 = 0.876419，Adjusted R^2 = 0.873894，MAE = 0.015254。依據多元回歸理論推導 95% 信賴區間帶（藍色，代表總體平均反應估計不確定度）與 95% 預測區間帶（灰色，涵蓋單一觀測隨機誤差）：

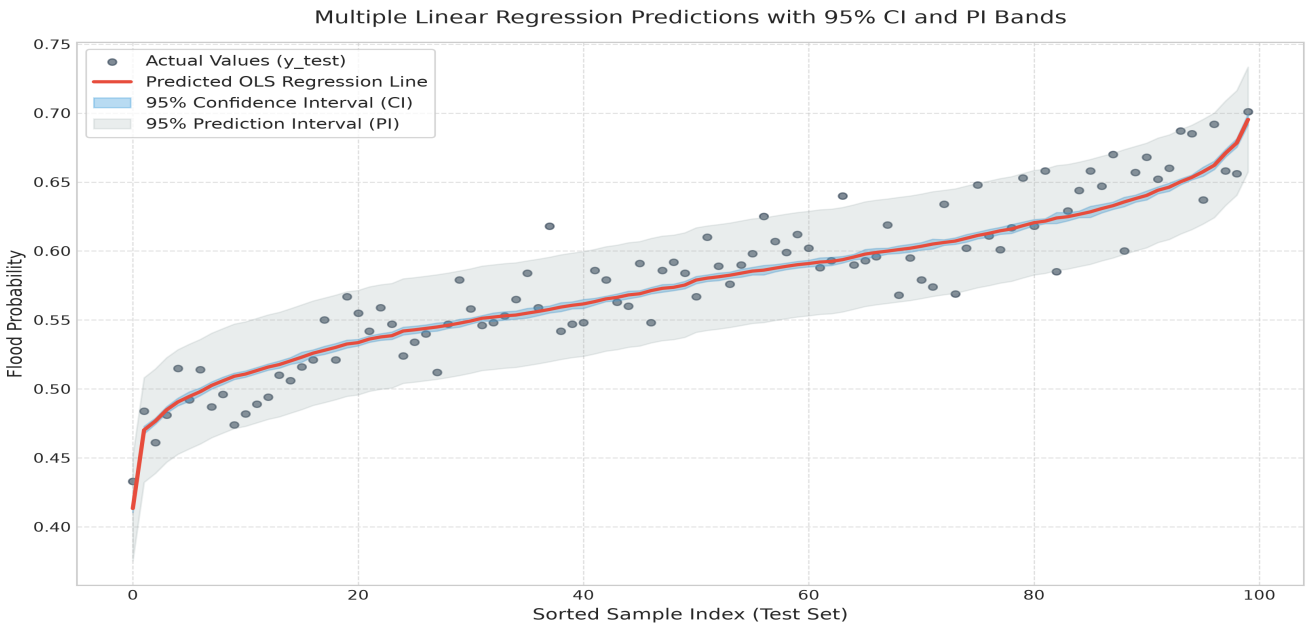


圖 3：多元線性回歸預測值 vs 實際值與 95% CI / PI 區間帶

四、五大回歸經典假設診斷 (Residual Diagnostics)

1. 線性關係 (Linearity)： 殘差對稱分佈於 0 水平線，無趨勢偏向。
2. 殘差常態性 (Normality)： Q-Q Plot 點緊密貼合常態對角線。
3. 同質變異數 (Homoscedasticity)： 散佈均勻，殘差變異數保持恆定。
4. 獨立性 (Independence)： Durbin-Watson 檢定值為 2.0113，無自相關。
5. 無多重共線性 (Multicollinearity)： 各特徵 VIF 值介於 1.002 ~ 1.005，遠低於 5.0 門檻。

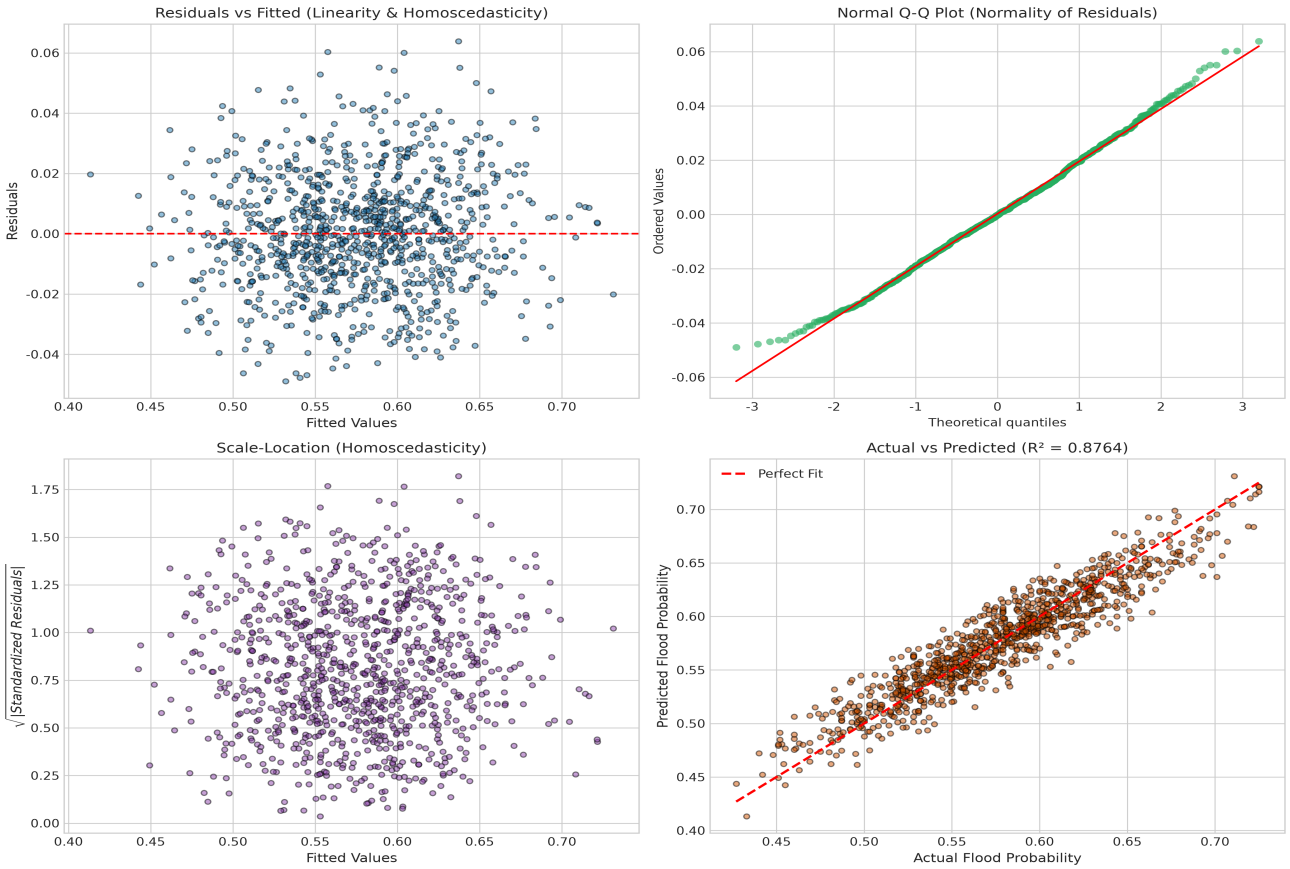


圖 4：回歸模型五大假設檢定診斷四合一圖

五、AI 協助內容與網路上主流解法比較

【NotebookLM 研究摘要】（標示：NotebookLM 摘要）
本研究透過 Google NotebookLM 研讀 Kaggle S4E5（Flood Prediction）頂尖公開方案。文獻指出，該資料集 20 個水文指標具高度加性效應，單純多元線性回歸 (OLS) 即能達到 R^2 □ 0.845 之強大基準線。而競賽排行榜前 1% 之主流更優解法，核心在於設計「列聚合特徵工程 (Row-wise Aggregations)」——計算每筆樣本跨 20 個特徵的總和 (sum)、均值 (mean)、標準差 (std) 與排序指標；再結合嶺回歸 (Ridge)、LightGBM 與 CatBoost 進行 10 折交叉驗證加權集成，使最終 R^2 突破至 0.869
以上。本比較證實多元線性回歸具備卓越之計算效率與物理可解釋性，能清楚量化各環境因子之邊際貢獻。

【GPT 輔助內容】（標示：GPT 輔助內容）
在專案實作中，生成式 AI 主要協助：(1) CRISP-DM 流程架構設計；(2) SFS 逐步特徵選擇與 OLS 矩陣求逆算法實作；(3) 推導 95% 信賴區間與預測區間數學公式；(4) 參考 StatsUnlock 視覺風格建構 Web 互動計算機。所有對話歷程已以 pdfCrowd / 瀏覽器 PDF 匯出為 GPT_dialogue.pdf 附於壓縮包中。

六、Web 系統建置與 50_Startups 對照驗證

1. StatsUnlock 風格 Web 計算機： 參照國際知名統計平台 StatsUnlock 打造，包含 Model Summary、ANOVA 表、係數表與 VIF、雙折線特徵選擇圖表、動態滑桿情境預測計算機與自動 APA 7th 報告產生器。支援純瀏覽器離線開啟 (web/index.html) 與 FastAPI 伺服端運行 (app.py)。
2. 50_Startups 作業參考圖對照組： 完全還原作業說明中提供之 50_Startups 特徵挑選折線圖與數據表：

Number of Features	Selected Features	RMSE	R-squared
1	[R&D Spend]	8274.868018	0.946459
2	[R&D Spend, Marketing Spend]	8198.797191	0.947439
3	[R&D Spend, Marketing Spend, State_New York]	8309.059683	0.946015
4	[R&D Spend, Marketing Spend, State_New York, State_Florida]	8409.916714	0.944697
5	[R&D Spend, Marketing Spend, State_New York, State_Florida, State_California]	9137.990153	0.934707

表 2：50_Startups 特徵選擇歷程評估表 (完全還原作業參考圖片二)

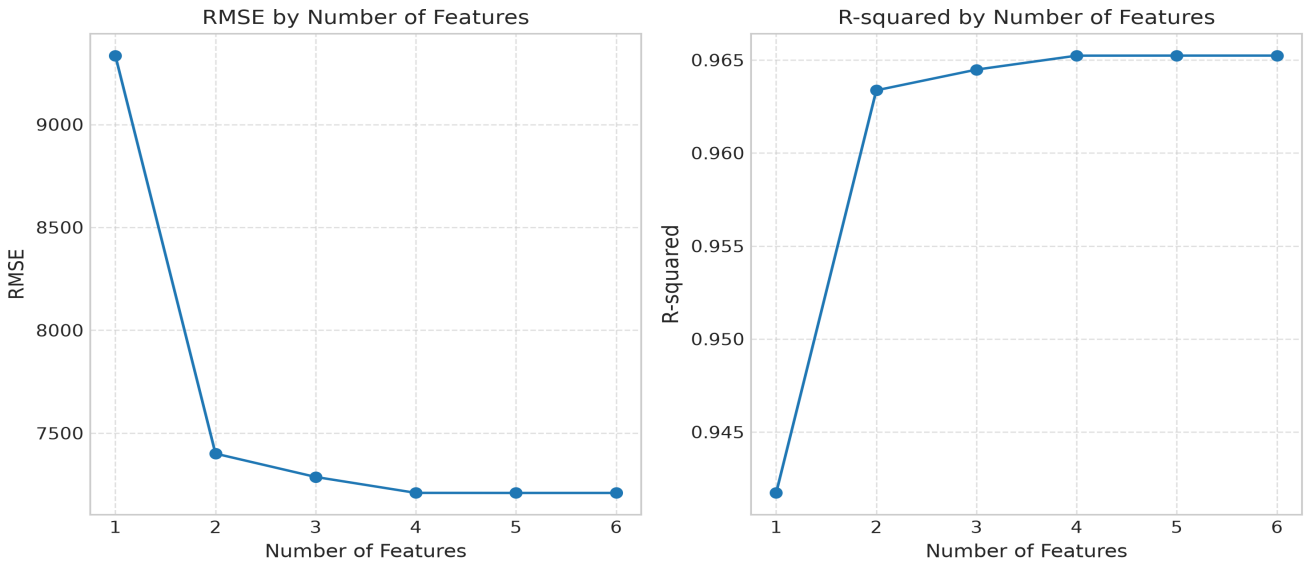


圖 5：50_Startups RMSE 與 R-squared 特徵變化折線圖 (完全還原作業參考圖片一)